

TelcoChurn Project: Modelo Desplegado de Predicción de Fuga.

Entrega 1

Despliegue De Soluciones Analíticas

Equipo: Andres Mauricio Rueda Blanco - 202524511, Ferney Duarte Garzón - 202526327

Problema de Negocio

En entornos B2B y de servicios recurrentes, la adquisición de nuevos clientes representa un costo significativamente mayor que la retención de los actuales. Actualmente, los equipos de gestión de cuentas (Account Managers) operan de manera reactiva, enterándose de la insatisfacción del cliente cuando la decisión de cancelar el servicio ya ha sido tomada. El problema principal radica en la falta de una herramienta analítica que consolide el comportamiento histórico y transaccional para identificar de forma proactiva qué cuentas están en riesgo. Esta carencia impide realizar un triage operativo adecuado que priorice los esfuerzos de retención hacia los clientes de mayor valor comercial para la compañía.

Pregunta de negocio

¿Cuáles son los clientes que presentan la mayor probabilidad de cancelar su suscripción en el corto plazo y qué factores operativos influyen más en esa decisión, para así focalizar las estrategias de retención?

Alcance del Proyecto

El alcance de este proyecto comprende el diseño, desarrollo y despliegue de un Producto Mínimo Viable (MVP) funcional para la predicción de fuga de clientes (Churn). La solución analítica contempla los siguientes componentes:

Ingeniería de Datos y Modelado Supervisado:

- Procesamiento, limpieza y análisis exploratorio (EDA) del conjunto de datos *Telco Customer Churn*.
- Entrenamiento, validación y selección de un modelo de Machine Learning de clasificación binaria (ej. Regresión Logística o Random Forest) que asigne una probabilidad de fuga (0% a 100%) a cada cliente.
- Empaquetamiento del modelo final y versionamiento de los datos y el código utilizando herramientas estándar (DVC y Git).

Desarrollo del Tablero Interactivo (Frontend):

Creación de una interfaz web estática de usuario que consuma la API desarrollada junto a la implementación de herramientas de analítica visual enfocadas en la toma de decisiones, incluyendo:

- **Simulador de Escenarios:** Para evaluar en tiempo real cómo cambia la probabilidad de fuga al modificar variables de negocio (ej. cambiar un contrato a largo plazo o añadir soporte técnico).
- **Matriz de Priorización:** Visualización cruzada del riesgo de fuga frente a la facturación mensual (MRR) para identificar cuentas críticas.
- **Despliegue y Contenerización:** Contenerización de la solución completa (API y Tablero) garantizando su portabilidad y fácil ejecución en diferentes entornos, cumpliendo con los requerimientos técnicos de la materia.

Conjunto de Datos

Para este proyecto, se utilizará el conjunto de datos público **Telco Customer Churn** (disponible en Kaggle). Este set de datos estructurado contiene información histórica del comportamiento de los clientes de una empresa de telecomunicaciones a lo largo de un mes.

- **Total de registros (filas):** 7,043 clientes únicos.
- **Total de variables (columnas):** 21 variables (20 predictoras y 1 variable objetivo).

A continuación, se detalla el diccionario de datos clasificado por dimensiones de negocio:

Dimensión	Variable	Tipo de Dato	Descripción / Valores Posibles
Identificación	customerID	Alfanumérico	Identificador único asignado a cada cliente.
Demográfica	gender	Categorica	Género del cliente (Female, Male).
Demográfica	SeniorCitizen	Binaria (Int)	Indica si el cliente es de la tercera edad (1 = Sí, 0 = No).
Demográfica	Partner	Categorica	Indica si el cliente tiene pareja (Yes, No).
Demográfica	Dependents	Categorica	Indica si el cliente tiene personas a cargo (Yes, No).
Servicios	PhoneService	Categorica	Indica si el cliente tiene servicio telefónico (Yes, No).
Servicios	MultipleLines	Categorica	Indica si tiene múltiples líneas telefónicas (Yes, No, No phone service).
Servicios	InternetService	Categorica	Tipo de proveedor de internet del cliente (DSL, Fiber optic, No).
Servicios	OnlineSecurity	Categorica	Indica si tiene el servicio de seguridad en línea extra (Yes, No, No internet service).
Servicios	OnlineBackup	Categorica	Indica si tiene el servicio de respaldo en línea (Yes, No, No internet service).
Servicios	DeviceProtection	Categorica	Indica si tiene un plan de protección de equipos (Yes, No, No internet service).
Servicios	TechSupport	Categorica	Indica si cuenta con soporte técnico prioritario (Yes, No, No internet service).
Servicios	StreamingTV	Categorica	Indica si el cliente usa el servicio para ver TV por streaming (Yes, No, No internet service).
Servicios	StreamingMovies	Categorica	Indica si el cliente usa el servicio para ver películas (Yes, No, No internet service).
Cuenta y Pagos	tenure	Numérica (Int)	Antigüedad del cliente en meses.
Cuenta y Pagos	Contract	Categorica	Tipo de contrato del cliente (Month-to-month, One year, Two year).
Cuenta y Pagos	PaperlessBilling	Categorica	Indica si el cliente tiene facturación electrónica (Yes, No).
Cuenta y Pagos	PaymentMethod	Categorica	Método de pago (Electronic check, Mailed check, Bank transfer (auto), Credit card (auto)).
Cuenta y Pagos	MonthlyCharges	Numérica (Float)	Monto cobrado al cliente mensualmente.
Cuenta y Pagos	TotalCharges	Numérica (Float)	Monto total histórico cobrado al cliente.
Objetivo	Churn	Categorica	Variable a predecir. Indica si el cliente canceló el servicio en el último mes (Yes, No).

Link Data:

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Repositorios

Link Git Hub:

<https://github.com/fduarteg2/ProjectChurn>

 fduarteg2 / ProjectChurn

🔍 Type to search

 +

Code

Issues

Pull requests

Actions

Projects

Wiki

Security and quality

Insights

Settings

dab has been added as a collaborator on the repository.

General

Access

🔍 Collaborators

Moderation options

Code and automation

Branches

Tags

Rules

Actions

Webhooks

Copilot

Environments

Codespaces

Pages

Collaborators and teams

 **Public repository**

This repository is public and visible to anyone

Manage visibility

Direct access

1 entity has access to this repository. [0 collaborators](#), [1 invitation](#).

Manage access

☐ Select all

Type

🔍 Find a collaborator...

 **a-ruedab**

Awaiting a-ruedab's response

Pending Invite



< Previous

Next >




GitHub repository page for **ProjectChurn** by **fduarteg2**. The repository is public and has 1 branch (main) and 0 tags. The commit history shows 2 commits: "Entrega 1.ipynb" (1 minute ago) and "README.md" (2 minutes ago). The README file is visible, titled "ProjectChurn". The right sidebar shows the repository's metadata: no description, website, or topics provided; 0 stars, 0 forks, and 0 watchers. The "About" section is empty.

Repositorio DVC en uso para los datos.

GitHub repository page for **ProjectChurn** by **fduarteg2**, showing the latest commit. The repository is public and has 1 branch (main) and 0 tags. The commit history shows 4 commits: ".dvc" (14 minutes ago), ".dvcignore" (14 minutes ago), ".gitignore" (2 minutes ago), and "Entrega 1.ipynb" (44 minutes ago). The README file is visible, titled "ProjectChurn". The right sidebar shows the repository's metadata: no description, website, or topics provided; 0 stars, 0 forks, and 0 watchers. The "About" section is empty.

```
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % git add .
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % git commit -m "Added data"
[main 53fd02c] Added data
3 files changed, 6 insertions(+)
create mode 100644 .gitignore
create mode 100644 Telco-Churn.csv.dvc
create mode 100644 Telco-Churn.xlsx
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % git remote add origin https://github.com/fduarteg2/ProjectChurn.git
error: remote origin already exists.
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % git push -u origin main
Enumerating objects: 12, done.
Counting objects: 100% (12/12), done.
Delta compression using up to 10 threads
Compressing objects: 100% (8/8), done.
Writing objects: 100% (11/11), 660.87 KiB | 19.44 MiB/s, done.
Total 11 (delta 1), reused 0 (delta 0), pack-reused 0
remote: Resolving deltas: 100% (1/1), done.
To https://github.com/fduarteg2/ProjectChurn.git
25fa065..53fd02c main -> main
branch 'main' set up to track 'origin/main'.
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn %
```

INFORME EXPLORACIÓN DE LOS DATOS (EDA)








	mean	50%	std	skewness	kurtosis
tenure	32.371149	29.000	24.559481	0.239540	-1.387372
MonthlyCharges	64.761692	70.350	30.090047	-0.220524	-1.257260
TotalCharges	2283.300441	1397.475	2266.771362	0.961642	-0.231799

La antigüedad del cliente (*tenure*), una variable demográfica clave, es el principal indicador del momento de riesgo. Los datos muestran una fuerte concentración de clientes en sus primeros cinco meses, lo que indica que la probabilidad de fuga es inminentemente alta durante esta fase de adopción.

Por otro lado, la facturación mensual (*MRR*) revela un bloque denso de usuarios que pagan tarifas altas, entre \$70 y \$105. Estos clientes representan el mayor riesgo de impacto financiero para la compañía. Esta variable alimentará el eje Y de la Matriz de Priorización, si el modelo detecta a un cliente de alta facturación con riesgo de fuga, el gestor de cuentas debe priorizar su contacto inmediato para ofrecer empaquetamientos o revisiones de servicio que aseguren la retención.

Finalmente, la facturación total acumulada (*TotalCharges*) confirma que la mayoría de los usuarios no alcanza a madurar lo suficiente en el tiempo para generar una rentabilidad histórica alta.






Al evaluar la configuración de las cuentas, resalta que la mayor parte de la base actual (cerca de 3,800 clientes) opera bajo contratos de mes a mes (Month-to-month), superando ampliamente a quienes tienen compromisos de uno o dos años. Operativamente, esto significa que la compañía se enfrenta a un escenario de altísima volatilidad, ya que la barrera de salida para la mayoría de los usuarios es prácticamente nula.

Por otro lado, la infraestructura del negocio recae fuertemente sobre el internet de fibra óptica (siendo el servicio dominante con más de 3,000 usuarios), pero existe una brecha crítica en la adopción de servicios complementarios de protección. Una abrumadora mayoría de clientes (alrededor de 3,500) no cuenta con Soporte Técnico (*TechSupport*) ni Seguridad en Línea (*OnlineSecurity*). Esto representa un riesgo operativo latente, ante cualquier falla en el servicio de fibra, el usuario carece de una red de apoyo técnico que amortigüe su insatisfacción.

Finalmente, en el aspecto transaccional, el cheque electrónico (*Electronic check*) es el método de recaudo predominante (más de 2,300 usuarios), mientras que las opciones de cobro automático por tarjeta de crédito o transferencia bancaria tienen una participación considerablemente menor. Esta falta de automatización en los pagos obliga al cliente a realizar un esfuerzo manual periódico, lo que facilita la decisión de cancelar el servicio de forma impulsiva en caso de un mal momento.


Distribucion de los Churn segun las respectivas categorias.



El tipo de contrato representa uno de los factores más críticos en la retención. La evidencia muestra que los clientes con acuerdos de mes a mes (*Month-to-month*) tienen una altísima probabilidad de cancelación, alcanzando un 42.7% de fuga en su segmento. Por el contrario, los compromisos a largo plazo reducen drásticamente este riesgo, los contratos a un año caen al 11.3% y los de dos años llegan a un mínimo de 2.8%. Operativamente, el equipo de gestión de cuentas debe priorizar estrategias comerciales que incentiven a los clientes mensuales a migrar hacia contratos anuales, creando así una barrera de salida mucho más sólida.

A nivel de servicios consumidos, la tecnología de conexión enciende una alerta operativa importante. Los usuarios de fibra óptica (*Fiber optic*) presentan una tasa de fuga del 41.9%, una cifra muy superior al 19.0% que registran los clientes con servicio DSL. Esta vulnerabilidad se explica en gran medida al cruzarlo con el nivel de acompañamiento: los clientes que no cuentan con soporte técnico (*TechSupport = No*) tienen una probabilidad de cancelación del 41.6%, frente a un controlado 15.2% de quienes sí cuentan con esta ayuda. Para mitigar esto, las estrategias de retención deben enfocarse en auditar la calidad del servicio de fibra óptica y realizar campañas proactivas para empaquetar u ofrecer activamente el soporte técnico, evitando que el usuario enfrente problemas de red sin ayuda.

Finalmente, el método de pago influye significativamente en la decisión de abandono. El uso de cheque electrónico (*Electronic check*) es la modalidad más riesgosa, presentando una alarmante tasa de fuga del 45.3%, la más alta de todas las variables visualizadas. En contraste, las modalidades de cobro automático, como la tarjeta de crédito (15.2%) y la transferencia bancaria (16.7%), fidelizan mucho mejor al usuario. Como acción táctica a corto plazo, la operación debe diseñar campañas que ofrezcan beneficios o descuentos a cambio de que los usuarios inscriban métodos de pago automáticos, reduciendo la fricción manual mes a mes y disminuyendo la cancelación impulsiva.




Al analizar la distribución comparativa entre clientes retenidos y fugados, la antigüedad del cliente (*tenure*) se confirma como la variable de riesgo más crítica. El gráfico de caja (*boxplot*) revela que la mitad de los clientes que cancelan su suscripción lo hacen en sus primeros 10 meses de servicio (mediana), mientras que los usuarios retenidos muestran una

madurez operativa mucho mayor, con una mediana cercana a los 38 meses. En consecuencia, el impacto financiero es severo: los clientes fugados abandonan la empresa antes de generar un valor histórico significativo, registrando una mediana de cargos totales (*TotalCharges*) por debajo de los \$1,000, frente a los casi \$1,800 que acumulan los clientes fieles. Operativamente, esto exige que las estrategias de retención se concentren de forma agresiva durante el primer año de servicio, blindando la experiencia del usuario antes de que alcance el punto de quiebre.

Por otro lado, la facturación mensual (*MonthlyCharges*) expone un claro factor de fricción económica. La evidencia visual demuestra que los clientes que deciden abandonar la compañía pagan tarifas significativamente más altas, concentrando su mediana en torno a los \$80 mensuales, frente a los \$65 de mediana de quienes permanecen activos. Esto indica que a mayor costo mensual, el cliente es mucho más sensible a fallas en el servicio o percibe una menor relación costo-beneficio. El equipo de gestión de cuentas debe utilizar este indicador directamente en la Matriz de Priorización del dashboard para identificar proactivamente a las cuentas que superan los \$70 mensuales y brindarles un soporte o acompañamiento premium que justifique su inversión.

Finalmente, el gráfico de dispersión ilustra de manera contundente la relación matemática y de negocio entre la retención y la rentabilidad. La tendencia alcista confirma que la única forma operativa de escalar los ingresos de la compañía es garantizando la permanencia a largo plazo. Se observan distintas franjas de facturación, pero el objetivo estratégico debe apoyarse en herramientas como el Simulador de Escenarios para evaluar tácticas (como *cross-selling* o mejoras contractuales) que permitan desplazar a la gran masa de usuarios que se encuentra estancada en los primeros 20 meses hacia la derecha del gráfico, transformándolos en clientes de alto valor a largo plazo.

Mockup Tool



La solución opera como un producto de datos integral diseñado para el **triage operativo** y la toma de decisiones basada en evidencia:

- **Triage y Simulación:** Interfaz interactiva donde el gestor ajusta variables del cliente (contrato, soporte, etc.) y visualiza en tiempo real la variación en la probabilidad de fuga (*Churn*).
- **Motor Predictivo:** API REST (Backend) que procesa datos en tiempo real y devuelve la predicción de riesgo exacta.
- **Priorización Estratégica:** Matriz de gestión que cruza el riesgo con el valor económico, permitiendo identificar rápidamente los clientes de "Zona Crítica" (Alto Valor + Alto Riesgo).
- **Explicabilidad (Insights):** Módulo que desglosa los 3 factores principales que impulsan el riesgo de cada cliente, proporcionando al equipo de ventas argumentos concretos para la retención.

- **Arquitectura Profesional:** Sistema empaquetado en contenedores para despliegue ágil, con trazabilidad garantizada mediante **Git** (código) y **DVC** (datos).

Responsabilidades

Fase del Proyecto	Actividad	Responsable(s)
Definición	Documentación de problema, alcance y pregunta de negocio	Ambos
EDA	Exploración inicial, limpieza de datos y reporte de hallazgos	Ferney Duarte
Modelado	Entrenamiento, validación y selección del modelo predictivo	Andrés Rueda
API	Desarrollo de la API REST para servir inferencias	Andrés Rueda
Frontend	Diseño e implementación del dashboard en Streamlit	Ambos
Despliegue	Contenerización (Docker) y despliegue del MVP	Ambos
Control	Gestión de versiones en Git y DVC	Ambos

Descripción de Responsabilidades

Ferney Duarte Garzón

- Lideró el **Análisis Exploratorio de Datos (EDA)**, transformando la base de datos Telco-Churn.xlsx en hallazgos accionables para el negocio.
- Responsable de la documentación formal del contexto, la justificación del problema y la definición de las métricas clave de éxito.
- Co-desarrollador de la interfaz de usuario en Streamlit, enfocándose en la lógica del **Simulador de Escenarios** y la **Matriz de Priorización**.
- Responsable de la configuración técnica de la infraestructura de despliegue en contenedores Docker y la integración del flujo de trabajo en Git.

Andrés Rueda

- Lideró la **fase de modelado predictivo**, incluyendo el preprocesamiento avanzado, la selección del algoritmo de clasificación y la optimización de hiperparámetros para maximizar el rendimiento del modelo.
- Responsable del desarrollo del **Backend (API REST)**, asegurando la comunicación eficiente entre el modelo entrenado y la interfaz de usuario.
- Co-desarrollador de la interfaz de usuario en Streamlit, encargado de la visualización de los resultados de inferencia y la explicabilidad del modelo (SHAP/feature importance).
- Responsable del versionamiento de los datasets utilizados para el entrenamiento mediante **DVC**, asegurando la trazabilidad de los datos durante todo el proyecto.