

TelcoChurn - Entrega 2

TelcoChurn — Predicción de Fuga de Clientes

Entrega 2 · Despliegue de Soluciones Analíticas

Equipo: Ferney Duarte Garzón (202526327) · Andrés Mauricio Rueda Blanco (202524511)

Repositorio: github.com/fduarteg2/ProjectChurn

1. Resumen del problema

Contexto. En entornos B2B y de servicios recurrentes, retener un cliente cuesta significativamente menos que adquirir uno nuevo. Hoy los equipos de gestión de cuentas (Account Managers) operan de forma reactiva: se enteran de la insatisfacción del cliente cuando la cancelación ya fue decidida. Falta una herramienta analítica que identifique proactivamente qué cuentas están en riesgo, para priorizar el esfuerzo de retención hacia los clientes de mayor valor.

Pregunta de negocio. ¿Cuáles clientes presentan mayor probabilidad de cancelar su suscripción en el corto plazo y qué factores operativos influyen más en esa decisión, para focalizar las estrategias de retención?

Alcance. MVP funcional compuesto por: (i) modelado supervisado de clasificación binaria de fuga (Churn), con versionamiento de datos (DVC) y experimentos (MLflow); (ii) tablero interactivo (Streamlit) con simulador de escenarios, matriz de priorización riesgo-valor y explicabilidad de factores.

Datos. [Telco Customer Churn](#) (Kaggle): 7,043 clientes, 21 variables (20 predictoras + Churn) agrupadas en identificación, demografía, servicios contratados, y cuenta/pagos.

2. Modelos desarrollados y su evaluación

Preprocesamiento y selección de características. Se descarta customerID (no aporta señal predictiva). TotalCharges se convierte a numérico e imputa como 0 en los 11 registros vacíos (clientes con tenure=0, sin facturación acumulada). Las 3 variables numéricas (tenure, MonthlyCharges, TotalCharges) se imputan por mediana y escalan (StandardScaler); las 16 variables categóricas se imputan por moda y codifican con OneHotEncoder, todo dentro de un ColumnTransformer encadenado en un Pipeline de scikit-learn. No se aplicó selección adicional de variables dado el tamaño moderado del dataset y el uso de modelos con regularización (Logística) o ensamble (Random Forest, Gradient Boosting), que manejan bien la redundancia entre variables. Split 80/20 estratificado por Churn, random_state=42.

Experimentación con MLflow. Se entrenaron 3 familias con distintas variaciones de hiperparámetros (9 corridas en total), cada una registrada como un *run* en MLflow con sus parámetros, métricas (accuracy, precision, recall, F1, ROC AUC), matriz de confusión y el modelo serializado como artefacto:

- Reg. Logística baseline interpretable, `class_weight=balanced`, $C \in \{0.01, 0.1, 1, 10\}$.
- Random Forest `class_weight=balanced`, 3 combinaciones de `n_estimators/max_depth`.
- Gradient Boosting 2 combinaciones de `n_estimators/learning_rate/max_depth`.

Run	Modelo	Accuracy	Precision	Recall	F1	ROC AUC
rf_n400_d10	Random Forest	0.768	0.548	0.719	0.622	0.840
logreg_C0.01	Log. Regression	0.743	0.510	0.786	0.619	0.838
logreg_C0.1	Log. Regression	0.742	0.509	0.786	0.618	0.841
logreg_C1	Log. Regression	0.738	0.504	0.783	0.614	0.842
rf_n200_d5	Random Forest	0.738	0.504	0.783	0.614	0.839
logreg_C10	Log. Regression	0.737	0.503	0.783	0.613	0.841
gb_n200_lr0.05	Gradient Boosting	0.805	0.669	0.524	0.588	0.844
gb_n100_lr0.1	Gradient Boosting	0.803	0.666	0.516	0.581	0.843
rf_n400_dNone	Random Forest	0.782	0.618	0.468	0.533	0.821




Figura 1. Comparación de F1-score de los 9 experimentos registrados en MLflow, coloreados por familia de modelo.

Modelo seleccionado: rf_n400_d10 (Random Forest, 400 árboles, profundidad máxima 10, `class_weight=balanced`). Ofrece el mejor F1 (0.622) con el mejor equilibrio precision/recall del conjunto, y un ROC AUC competitivo (0.840), evitando el sobreajuste que exhibe la variante sin límite de profundidad. Este modelo se re-entrena sobre el 100%

de los datos (`train_final_model.py`) y se empaqueta como `modelo_churn_final.joblib` para ser consumido por el tablero.

3. Observaciones y conclusiones sobre los modelos

- **La Regresión Logística** (baseline) logra el recall más alto del experimento (~0.78-0.79) a costa de precisión baja (~0.50-0.51): es un modelo "sobre-alertador" — señala muchos clientes como riesgo, capturando casi todos los churners reales pero con más falsas alarmas. Útil como piso interpretable de referencia.
- **Gradient Boosting** obtiene la mayor accuracy/precisión (0.80 / 0.67) de las 9 corridas, pero su recall cae a ~0.52. Para el caso de negocio — donde el costo de *no* detectar a un cliente que se va (falso negativo) suele ser mayor que el de una alerta de más — este modelo es subóptimo pese a su alta accuracy aparente.
- **Random Forest sin límite de profundidad** (`rf_n400_dNone`) sobreajusta: accuracy más alta que las otras variantes de RF (0.78) pero el recall se desploma a 0.47. Confirma que restringir `max_depth` mejora la generalización sobre el conjunto de prueba en este dataset.
- **El modelo elegido (`rf_n400_d10`)** prioriza capturar clientes en riesgo (recall 0.72) sin sacrificar demasiada precisión (0.55) — el balance más adecuado para un flujo de triage donde un Account Manager revisa manualmente la lista priorizada.
- La **importancia de variables** del modelo final (Gini importance, ver Figura 4) confirma los hallazgos del EDA de la Entrega 1: Contract, tenure, TotalCharges y MonthlyCharges son los factores más determinantes — hay coherencia entre el análisis exploratorio y el comportamiento aprendido por el modelo, lo que valida la relevancia de negocio de las predicciones.
- **Conclusión de negocio:** el modelo permite priorizar automáticamente a los clientes en "Zona Crítica" (alto riesgo + alto valor) visibles en la Matriz de Priorización del tablero (376 clientes en la muestra mostrada), habilitando el triage proactivo que motivó el proyecto.

4. Descripción del tablero desarrollado

Tablero construido en **Streamlit** (`tablero.py`), consume directamente el modelo empaquetado y ofrece 3 vistas orientadas a la toma de decisiones del equipo de gestión de cuentas:

4.1 Simulador de Escenarios

Permite seleccionar un cliente base y modificar variables de negocio (tipo de contrato, soporte técnico, servicio de internet, método de pago) para observar en tiempo real el cambio en la probabilidad de fuga predicha, comparándola contra el perfil original del cliente.



Figura 2. Simulador de Escenarios — cliente en alto riesgo (63%) bajo contrato mensual, sin soporte técnico y pago por cheque electrónico.

4.2 Matriz de Priorización

Cruza la probabilidad de fuga predicha (eje X) contra la facturación mensual (eje Y, proxy de valor del cliente), con umbrales ajustables. Identifica visualmente la "Zona Crítica" — clientes de alto riesgo y alto valor — que el equipo debe priorizar primero.




Figura 3. Matriz de Priorización — 376 clientes en Zona Crítica sobre una muestra de 1,500.

4.3 Factores de Influencia

Muestra la importancia relativa (Gini importance del Random Forest) de las variables de negocio agregadas por variable original — no por categoría del one-hot encoding — dando explicabilidad al equipo comercial sobre qué impulsa el riesgo.



Figura 4. Factores de Influencia — Contract, tenure y TotalCharges son las variables más determinantes.

5. Repositorio y control de versiones


Git / GitHub: github.com/fduarteg2/ProjectChurn (repositorio público). Historial de commits con evolución del proyecto desde la Entrega 1 (EDA) hasta la Entrega 2 (modelos, MLflow, DVC/S3, tablero):

Commit	Fecha	Descripción
6dd5cd6	2026-07-11	Actualización README, reproducibilidad con DVC y Mlflow
d044ef3	2026-07-11	Actualización IP e inclusión variante Gradient Boosting
f0c407b	2026-07-07	Actualiza IP de EC2 y agrega capturas de evidencia de MLflow
0cd1b4c	2026-07-07	Configura remoto DVC en S3 para compartir datos con el equipo
b17d468	2026-07-07	Agrega scripts de entrenamiento (MLflow) y PDFs de entregas
ebd1d13	2026-07-06	Agrega tablero interactivo (Streamlit)
53fd02c / f480e44	2026-06-24	Ingesta de datos y configuración inicial de DVC
25fa065	2026-06-24	EDA Project v1 (Entrega 1)

***DVC:** `TeLco-Churn.csv` versionado y sincronizado en remoto S3 (`s3://projectchurn-dvc-fduarteg2`), con versionado de bucket habilitado y acceso público bloqueado.*

5.1 Evidencia de aportes individuales en GitHub

La rúbrica de la Entrega 2 exige evidencia individual del uso del repositorio por cada integrante del equipo. A continuación, se incluye evidencia de commits realizados por ambos autores:



5.2 Fuentes de los modelos y del tablero

- Entrenamiento y comparación (MLflow): `train_churn_models.py`
- Entrenamiento del modelo final empaquetado: `train_final_model.py`

- Tablero interactivo (Streamlit): tablero.py

6. Evidencia de experimentos en MLflow (AWS EC2)

El servidor de MLflow se desplegó en una instancia AWS EC2 (IP pública 3.93.67.170, usuario ubuntu), donde se registraron las 9 corridas del experimento telco_churn_entrega2. Tras capturar la evidencia, el servicio de MLflow fue detenido (la instancia EC2 se mantiene activa, sin terminar).




Figura 5. Consola de AWS EC2 (región us-east-1, cuenta voclabs/user5140187=Ferney_Duarte) — instancia i-09d4d63389bc0095e (mlflow-churn-server), estado "En ejecución", IP pública 3.93.67.170.

```
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % ssh -i "Pass_Fer.pem" ubuntu@3.93.67.170 "whoami && hostname && curl -s ifconfig.me"
Warning: Identity file Pass_Fer.pem not accessible: No such file or directory.
ubuntu@3.93.67.170: Permission denied (publickey).
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % ssh -i "/Users/ferneyduartegarzon/Library/CloudStorage/GoogleDrive-fduarte1990@gmail.com/My Drive/_Personal/_Maestria/Despliegue/Pass_Fer.pem" ubuntu@3.93.67.170 "whoami && hostname && curl -s ifconfig.me"
ubuntu
ip-172-31-31-31
3.93.67.170
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn % ssh -i "/Users/ferneyduartegarzon/Library/CloudStorage/GoogleDrive-fduarte1990@gmail.com/My Drive/_Personal/_Maestria/Despliegue/Pass_Fer.pem" ubuntu@3.93.67.170 "whoami && hostname && curl -s ifconfig.me"
ubuntu
ip-172-31-31-31
3.93.67.170
ferneyduartegarzon@Ferneys-MacBook-Air ProjectChurn %
```

Figura 6. Terminal SSH conectado a la instancia EC2 — usuario ubuntu, host ip-172-31-31-31 e IP pública 3.93.67.170 visibles.




Figura 7. UI de MLflow en `http://3.93.67.170:8050` — listado de las 9 corridas del experimento `telco_churn_entrega2` (IP visible en la barra de direcciones).





Figura 8. Comparación de métricas entre corridas (parallel coordinates plot) en la UI de MLflow.



Run ID:	8f0af001ff794c13b165b6845c49d0e1	3d51ab6020a846e98116a3303784e7f3	2e85a33a0d2c4520ad5bfeafcf3e107c
Run Name:	rf_n400_d10	logreg_C0.01	gb_n200_lr0.05
Start Time:	2026-07-07 19:34:48	2026-07-07 19:34:21	2026-07-07 19:35:18
End Time:	2026-07-07 19:34:59	2026-07-07 19:34:27	2026-07-07 19:35:24
Duration:	10.8s	6.1s	6.5s

Parameters			
☐ Show diff only			
C		0.01	
class_weight	balanced	balanced	
learning_rate			0.05
max_depth	10		3
model_type	RandomForest	LogisticRegression	GradientBoosting
n_estimators	400		200

Metrics			
☐ Show diff only			
accuracy	0.768	0.743	0.805
f1_score	0.622	0.619	0.588
precision	0.548	0.51	0.669
recall	0.719	0.786	0.524
roc_auc	0.84	0.838	0.844

Figura 9. Detalle de parámetros y métricas de las corridas comparadas.

7. Reporte de trabajo en equipo

Equipo: Ferney Duarte Garzón (202526327) — Andrés Mauricio Rueda Blanco (202524511)

Fase	Actividad	Responsable	Evidencia
Modelado	Desarrollo de train_churn_models.py: pipeline de preprocesamiento y entrenamiento comparativo de 9 configuraciones (Regresión Logística, Random Forest, Gradient Boosting) con integración MLflow	Andrés Rueda	Commit d044ef3
Modelado	Desarrollo de train_final_model.py: entrenamiento y empaquetado del modelo final seleccionado	Andrés Rueda	Commit d044ef3
Infraestructura	Despliegue del servidor MLflow en instancia AWS EC2, configuración de persistencia (systemd lingering) y apertura de puertos	Ferney Duarte	Commits b17d468, f0c407b
Experimentación	Ejecución de las 9 corridas de entrenamiento contra el servidor	Ferney Duarte	Commit f0c407b,

Fase	Actividad	Responsable	Evidencia
Versionamiento	MLflow remoto y captura de evidencia		Soportes/
	Configuración del remoto DVC en S3 (bucket, políticas de acceso, versionado) y sincronización del dataset	Ferney Duarte	Commit 0cd1b4c
Frontend	Diseño e implementación del tablero en Streamlit (simulador de escenarios, matriz de priorización, factores de influencia)	Ambos	Commit ebd1d13
EDA (Entrega 1)	Análisis exploratorio de datos y documentación del contexto de negocio	Ferney Duarte	Commit 25fa065
Documentación	Redacción del reporte de la Entrega 2 y consolidación de soportes	Ferney Duarte	Este documento
Control de versiones	Gestión general del repositorio Git/GitHub	Ferney Duarte	Historial de commits